# Introduction à l'analyse exploratoire avec python

Pandas et Matplotlib


# Sommaire

- L’analyse exploratoire ?
- Pandas
- Matplotlib
- Statistiques descriptives
- Les graphiques
- Mise en pratique

# L’analyse exploratoire ?

Objectif : Obtenir une vision global d’un jeu de données en recherchant des régularités, des relation entre variables, ou même des groupes homogènes.

L’analyse exploratoire à aussi pour but de **détecter les valeurs rare ou manquante.**

Celle-ci peuvent ce voir accorder une importance plus grande qu’elle ne devrait en avoir.

# Pandas

- Offre des structure de données et fonctions conçues pour rendre l'utilisations de données structurés rapides, grâce à ces méthodes qui lui sont propres.
- Allie haute performance de calcule avec la souplesse des feuilles de calcul et des BD relationnelles.
- Fonctionnalité d'indexations évolué facilitant les opération de transformations de types, slicing, …

3 types d'objets dans Pandas :

- Series
- Dataframes : ensemble d'objets Series
- Panels : Ensemble d'objets Dataframe

# Pandas

## Le DataFrame :

Tableau à deux dimensions, avec un ensemble ordonnées de colonnes, avec des étiquettes de colonnes et de lignes.

## Une Série :

Similaire à un tableau unidimensionnel qui contient des données au quels sont associées un ensemble d'étiquettes appelées « index ». Un DataFrame est constitué de plusieurs Séries.

# Pandas : Types d’objets

- Types de données :
  - Float
  - Int
  - Bool
  - Datetime64[ns] : Date et horaire sans la time zone
  - Datetime[ns, tz] : Date et horaire avec la time zone
  - Timedelta[ns] : Différence de date et horaire (seconde, minute, …)
  - Category : pour les variables catégorielles
  - Object : chaîne de caractère.

# Matplotlib

- Bibliothèque python la populaire pour la production de graphique en mode trait.
- Production de graphiques destiné à la publication.
- Pratique pour explorer des graphes et explorer des données
- Peut être facilement combinée avec Pandas et d'autre bibliothèque scietifique.

# Statistiques descriptives

- Moyenne
- Médiane
  Valeur de la série qui permet de couper l'ensemble des valeurs en deux parties égales : mettant d'un côté une moitié des valeurs, et de l'autre côté l'autre moitié des valeurs.
- Quartiles
  La population peut être partagée en quatre sous-populations de même effectif. Les valeurs qui correspondent aux limites du partage sont des quartiles.
- Mode
  Le mode d’une série qualitative ou discrète est la modalité ou la valeur qui enregistre le plus grand effectif.

# Statistiques descriptives

- la variance
  mesure de la dispersion des valeurs d'un échantillon autour de sa moyenne. Elle exprime la moyenne des carrés des écarts à la moyenne
- L’écart-type
  Racine carré de la variance

# Les graphiques

Un graphique est une représentation de données statistiques. Et s'il existe plusieurs types de données, il y a aussi différents types de graphiques.

Se sont les **données** qui déterminent le type de graphique qui les représente et non le chargé d'études.

# Les graphiques

- Le diagramme circulaire est à privilégier pour représenter des séries dont le caractère est qualitatif. Les parts du diagramme ont des aires qui sont proportionnelles aux effectifs de chaque modalité.

- Le diagramme en barres est parfait lorsque le caractère est quantitatif discret. Il est également utilisé pour les caractères qualitatifs. C'est la longueur de chaque barre qui est proportionnelle aux effectifs ou aux pourcentages.

# Les graphiques

- La courbe est très souvent utilisée pour représenter une série quantitative en situation d'évolution, par exemple dans le temps. En réalité ce n'est pas une courbe puisqu'elle relie de façon rectiligne les points correspondant aux observations.

- Le nuage de points est idéal pour représenter des individus en fonction de deux critères quantitatifs, matérialisés par deux axes.

# Mise en pratique

```
#  Import de la librairi pandas avec l'allias pd

import pandas as pd
```

```
#Création d'un dataframe

df = pd.DataFrame({'Colonne1': [1.1, 2.7, 5.3], 'Colonne2': [2, 10, 9], 'Colonne3': ['oui', 'non', 'non']},
                  index = ['a', 'b', 'c'])

print(df)
```

```
   Colonne1  Colonne2 Colonne3
a       1.1         2      oui
b       2.7        10      non
c       5.3         9      non
```

# Mise en pratique

```python
# Import de données depuis un fichié Excel dans un dataframe

nom_colonnes = ['consomation', 'cylindres', 'deplacement',
                'puissance', 'poids', 'acceleration', 'annee', 'origine', 'nom']

data = pd.read_excel('Desktop\\Simplon\\DevData_Marseille\\Python\\autompg.xlsx',
                     index_col=None, header=None, names=nom_colonnes)
```

```python
# Afficher les premières lignes du dataframe
print(data.head())
```

```
  consomation  cylindres  deplacement  puissance  poids  acceleration  \
0         mpg  cylindres  déplacement  puissance  poids  accélération
1          18          8          307        130   3504            12
2          15          8          350        165   3693          11.5
3          18          8          318        150   3436            11
4          16          8          304        150   3433            12

             annee  origine                       nom
0  année de modèle  origine          Nom de la voiture
1               70         1  chevrolet chevelle malibu
2               70         1          buick skylark 320
3               70         1         plymouth satellite
4               70         1              amc rebel sst
```

# Mise en pratique

```
# Afficher les dimesions du dataframe
print(data.shape)
print(data.shape[0])
print(data.shape[1])
```

```
(398, 9)
398
9
```

```
#informations sur les données
print(data.info())
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 398 entries, 0 to 397
Data columns (total 9 columns):
consommation    398 non-null float64
cylindres       398 non-null int64
deplacement     398 non-null float64
puissance       392 non-null float64
poids           398 non-null int64
acceleration    398 non-null float64
annee           398 non-null int64
origine         398 non-null int64
nom             398 non-null object
dtypes: float64(4), int64(4), object(1)
memory usage: 28.1+ KB
None
```

# Mise en pratique

```
#description des données
print(data.describe())
```

```
       consommation   cylindres  deplacement   puissance        poids  \
count    398.000000  398.000000   398.000000  392.000000   398.000000
mean      23.514573    5.454774   193.425879  104.469388  2970.424623
std        7.815984    1.701004   104.269838   38.491160   846.841774
min        9.000000    3.000000    68.000000   46.000000  1613.000000
25%       17.500000    4.000000   104.250000   75.000000  2223.750000
50%       23.000000    4.000000   148.500000   93.500000  2803.500000
75%       29.000000    8.000000   262.000000  126.000000  3608.000000
max       46.600000    8.000000   455.000000  230.000000  5140.000000

       acceleration       annee     origine
count    398.000000  398.000000  398.000000
mean      15.568090   76.010050    1.572864
std        2.757689    3.697627    0.802055
min        8.000000   70.000000    1.000000
25%       13.825000   73.000000    1.000000
50%       15.500000   76.000000    1.000000
75%       17.175000   79.000000    2.000000
max       24.800000   82.000000    3.000000
```

# Mise en pratique

```
# Fréquences corisés
print(pd.crosstab(data['cylindres'],data['annee']))
```

| annee | 70 | 71 | 72 | 73 | 74 | 75 | 76 | 77 | 78 | 79 | 80 | 81 | 82 |
|---|---|---|---|---|---|---|---|---|---|---|---|---|---|
| cylindres | | | | | | | | | | | | | |
| 3 | 0 | 0 | 1 | 1 | 0 | 0 | 0 | 1 | 0 | 0 | 1 | 0 | 0 |
| 4 | 7 | 13 | 14 | 11 | 15 | 12 | 15 | 14 | 17 | 12 | 25 | 21 | 28 |
| 5 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 1 | 1 | 1 | 0 | 0 |
| 6 | 4 | 8 | 0 | 8 | 7 | 12 | 10 | 5 | 12 | 6 | 2 | 7 | 3 |
| 8 | 18 | 7 | 13 | 20 | 5 | 6 | 9 | 8 | 6 | 10 | 0 | 1 | 0 |

```
# Pourcantage corisés
print(pd.crosstab(data['cylindres'],data['annee'], normalize='index'))
```

| annee | 70 | 71 | 72 | 73 | 74 | 75 |
|---|---|---|---|---|---|---|
| cylindres | | | | | | |
| 3 | 0.000000 | 0.000000 | 0.250000 | 0.250000 | 0.000000 | 0.000000 |
| 4 | 0.034314 | 0.063725 | 0.068627 | 0.053922 | 0.073529 | 0.058824 |
| 5 | 0.000000 | 0.000000 | 0.000000 | 0.000000 | 0.000000 | 0.000000 |
| 6 | 0.047619 | 0.095238 | 0.000000 | 0.095238 | 0.083333 | 0.142857 |
| 8 | 0.174757 | 0.067961 | 0.126214 | 0.194175 | 0.048544 | 0.058252 |

# Mise en pratique

```
#accès à une ou plusieurs colonne
print(data[['nom', 'consommation']].head())
```

```
                          nom  consommation
0  chevrolet chevelle malibu          18.0
1          buick skylark 320          15.0
2         plymouth satellite          18.0
3              amc rebel sst          16.0
4                ford torino          17.0
```

```
# Affiche les valeurs 10 à 12
print(data['nom'][10:13])
```

```
10      dodge challenger se
11       plymouth 'cuda 340
12    chevrolet monte carlo
Name: nom, dtype: object
```

```
# Accées à la valeur de la première ligne, première colonne
print(data.iloc[0, 0])
# Accées à la valeur de la dernière ligne, première colonne
print(data.iloc[-1, 0])
```

```
18.0
31.0
```

# Mise en pratique

```
# Toutes les colonnes avec les ligne de 0 à 4
print(data.iloc[0:5,:])
```

```
   consommation  cylindres  deplacement  puissance  poids  acceleration  \
0          18.0          8        307.0      130.0   3504          12.0
1          15.0          8        350.0      165.0   3693          11.5
2          18.0          8        318.0      150.0   3436          11.0
3          16.0          8        304.0      150.0   3433          12.0
4          17.0          8        302.0      140.0   3449          10.5

   annee  origine                       nom
0     70        1  chevrolet chevelle malibu
1     70        1          buick skylark 320
2     70        1         plymouth satellite
3     70        1              amc rebel sst
4     70        1                ford torino
```

```
# Liste des voitures dont son de l'année 80
print(data.loc[data['annee']==80,:].head())
```

```
     consommation  cylindres  deplacement  puissance  poids  acceleration  \
309          41.5          4         98.0       76.0   2144          14.7
310          38.1          4         89.0       60.0   1968          18.8
311          32.1          4         98.0       70.0   2120          15.5
312          37.2          4         86.0       65.0   2019          16.4
313          28.0          4        151.0       90.0   2678          16.5
```

# Mise en pratique

```
# Pour que les graphique appraraissent dans le notebook
%matplotlib inline
#importation de la librairie
import matplotlib.pyplot as plt
```

```
# Histogramme de la puissance
data.hist(column='puissance')
```

```
array([[<matplotlib.axes._subplots.AxesSubplot object at 0x00000248D498DF60>]],
      dtype=object)
```

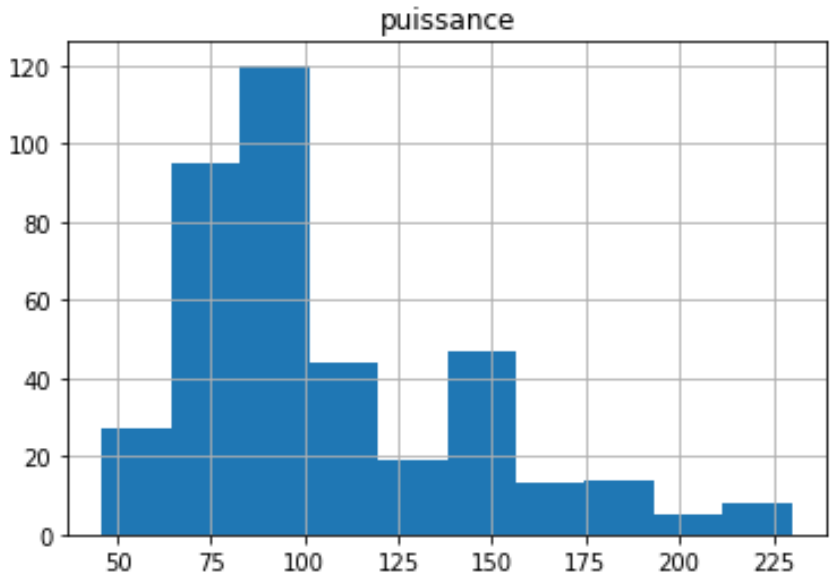

# Mise en pratique

```
# Nuage de point : consommation en fontiion de la puissance
# avec niveau de gris selon l'année
data.plot.scatter(x='puissance',y='consommation',c='annee')
```

```
<matplotlib.axes._subplots.AxesSubplot at 0x248d8654630>
```

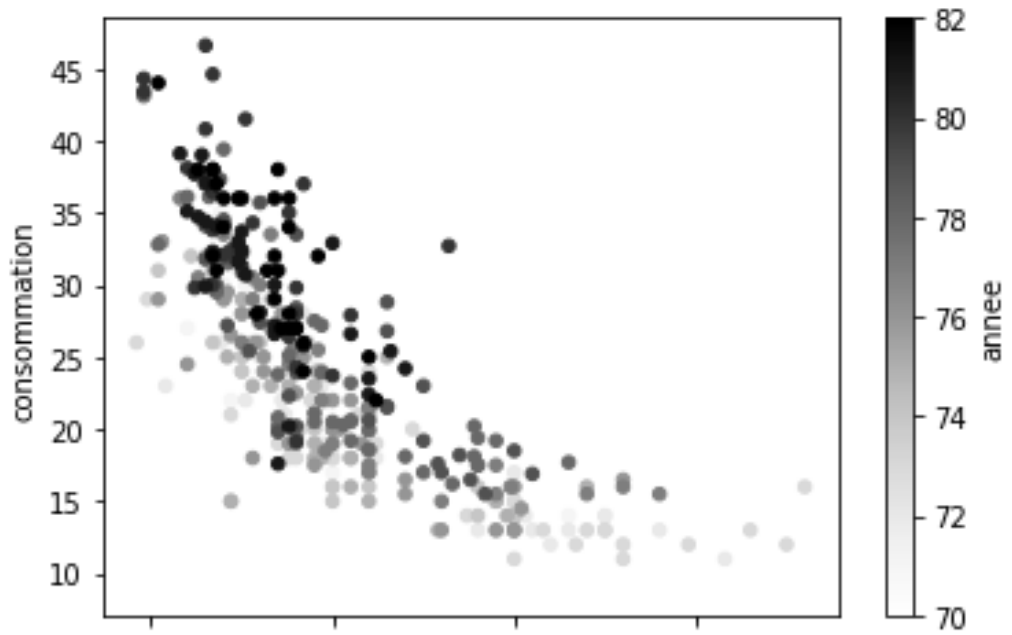

# Mise en pratique

```
pd.plotting.scatter_matrix(data.select_dtypes(exclude=['object']), figsize=(10, 10))
```

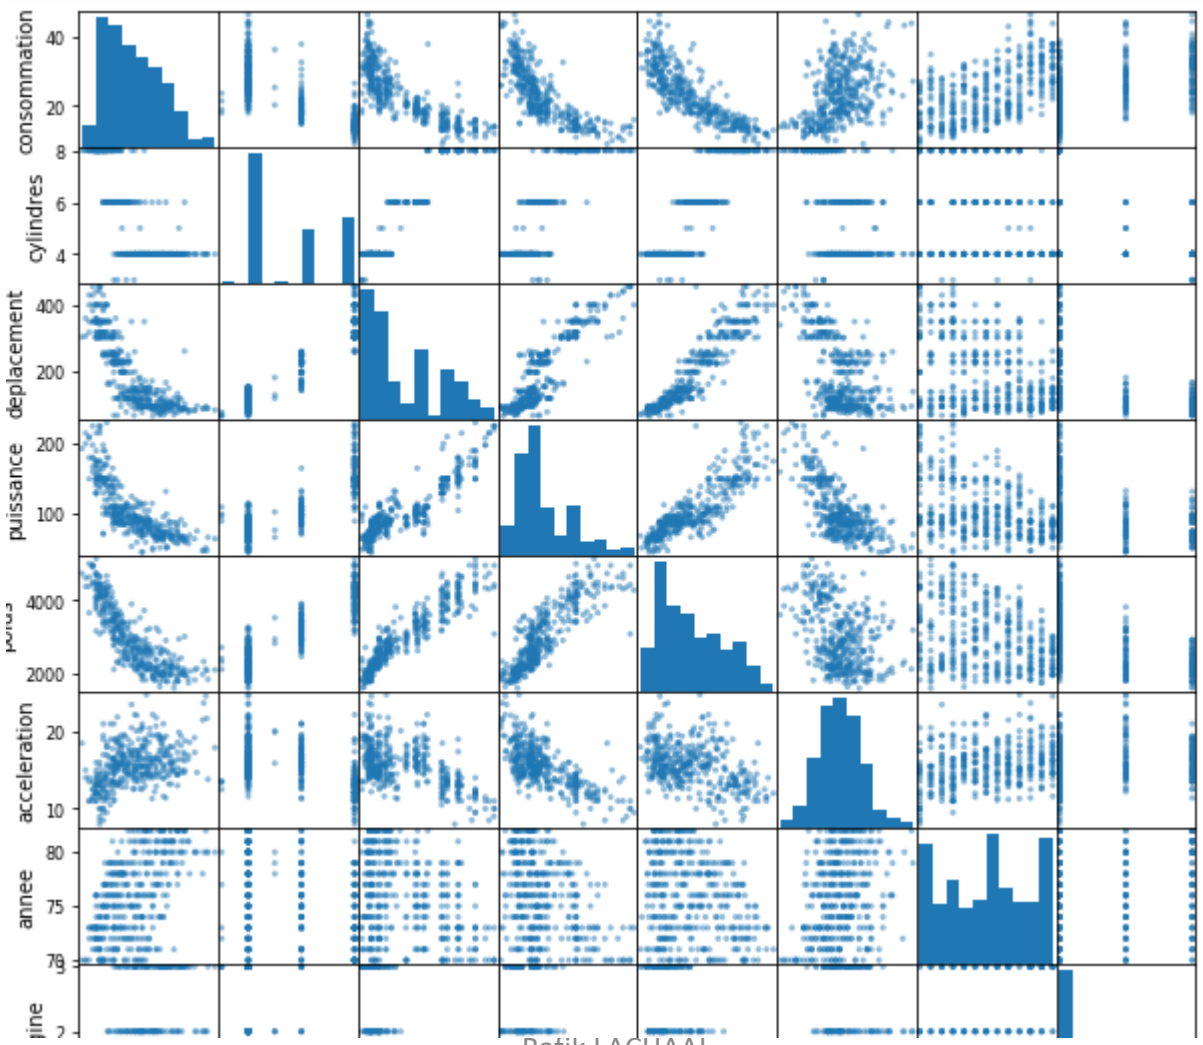

# Pratique

- A vous d’explorer Pandas et Matplotlib.
  - Importer les données avec Pandas
  - Produire les statistiques décrivant les données
  - Produire les graphique adapter au données

- Quel est la consommation moyenne des voitures de 8 cylindre ?